

R E T O 3

Análisis de Negocio con Business Analytics

Dataset: Shipping & Sales Data (2013–2017)

Jesús Gerardo Sánchez Cárdenas

Curso: Business Intelligence y Big Data · Unidad 3

Marzo 2026

1. Selección del Dataset

Para el desarrollo de este reto se ha utilizado el dataset Shipping Data, un conjunto de datos empresariales que contiene información detallada sobre pedidos de ventas realizados entre febrero de 2013 y febrero de 2017. El dataset fue facilitado como material del curso y está alineado con las fuentes de referencia indicadas (Kaggle, UCI Repository, Google Dataset Search).

El dataset recoge transacciones comerciales reales de una empresa distribuidora con actividad en tres categorías de producto: Furniture, Office Supplies y Technology. La riqueza de variables lo convierte en un candidato ideal para aplicar técnicas de Business Analytics orientadas a la toma de decisiones estratégicas.

1.1 Descripción General del Dataset

1.039 Registros Totales Pedidos únicos	19 Variables Columnas originales	4 años Período Feb 2013 – Feb 2017	3 Categorías Furniture, Office, Tech
--	--	--	--

Las variables originales del dataset incluyen información sobre el pedido (Order No, Order Date, Order Priority), el cliente (Customer Name, Customer Type), el agente comercial (Account Manager), el producto (Product Name, Product Category), la logística (Ship Mode, Ship Date) y las métricas económicas (Cost Price, Retail Price, Order Quantity, Sub Total, Discount %, Discount \$, Order Total, Shipping Cost, Total).

2. Importación y Exploración de Datos

El dataset fue importado y procesado con Python (pandas, numpy) para su análisis. A continuación se describe la estructura y las estadísticas descriptivas iniciales de las variables clave.

2.1 Estructura del Dataset

Variable	Tipo	Descripción	Valores únicos
Order No	Texto	Identificador único del pedido	1.038
Order Date / Ship Date	Fecha	Fecha de pedido y envío	731 / 697
Customer Type	Categorico	Tipo de cliente	4 (Consumer, Corporate, Home Office, Small Business)
Account Manager	Categorico	Agente comercial responsable	14 agentes
Product Category	Categorico	Categoría de producto	3 categorías
Order Priority	Categorico	Prioridad del pedido	5 niveles
Ship Mode	Categorico	Modalidad de envío	3 modos
Total	Numérico	Importe total del pedido (€)	Continuo
Profit	Numérico	Beneficio calculado (€)	Variable derivada

2.2 Análisis Descriptivo Inicial

Variable	Media	Mediana	Desv. Estándar	Mín.	Máx.
Total (€)	1.160,45	166,65	3.304,38	2,17	30.023,90
Profit (€)	540,79	72,64	1.449,89	0,54	13.905,29
Order Quantity	26,04	26,00	14,74	1	50
Retail Price (€)	45,68	7,28	104,98	1,14	599,99
Discount %	5,14%	5,00%	3,21%	0%	10%
Shipping Cost (€)	6,08	4,00	8,54	0,49	69,30
Lead Time (días)	1,98	2,00	1,86	0	27

Se observa una elevada dispersión en la variable Total, con una desviación estándar de 3.304 € sobre una media de 1.160 €, lo que indica la presencia de pedidos de gran volumen económico. El beneficio medio por pedido es de 540,79 €, con un margen relativo del 46,6%. El tiempo medio de entrega es de aproximadamente 2 días, lo que refleja una cadena logística eficiente.

3. Limpieza y Preparación de Datos

3.1 Detección y Tratamiento de Valores Nulos y Duplicados

Tras la importación y el ajuste del encabezado (el archivo Excel presenta una fila de título y una fila de encabezado), el dataset resultante contiene 1.039 registros. El análisis reveló:

- Valores nulos: 0 registros con valores faltantes en ninguna de las 19 columnas.
- Duplicados: 0 filas duplicadas detectadas. El dataset está libre de duplicidades.

3.2 Detección de Outliers

Se aplicó el método IQR (rango intercuartílico) con un umbral de 3x para identificar pedidos atípicos en la variable Total. Se detectaron 112 registros con valores superiores al límite superior ($Q3 + 3 \times IQR$). Dado que estos pedidos corresponden a operaciones comerciales legítimas de alto volumen (especialmente en la categoría Technology), se decidió conservarlos en el dataset y marcarlos con una variable indicadora Is_Outlier para su tratamiento diferenciado en los análisis.

3.3 Transformación y Normalización

Se realizaron las siguientes transformaciones sobre el dataset original:


- Conversión de tipos: las columnas de fecha (Order Date, Ship Date) se convirtieron a tipo datetime; las variables numéricas (Cost Price, Retail Price, Total, etc.) se convirtieron a tipo float.
- Normalización de cabeceras: se eliminó la fila de título del Excel y se asignaron nombres de columna limpios.

3.4 Creación de Nuevas Variables

Variable Nueva	Fórmula / Definición	Propósito
Profit	Total - (Cost Price × Order Quantity) - Shipping Cost	Mide el beneficio neto por pedido
Profit_Margin_Pct	(Profit / Total) × 100	Porcentaje de margen sobre ventas
Lead_Time_Days	Ship Date - Order Date (días)	Eficiencia logística
Year / Month / Quarter	Extraído de Order Date	Análisis de series temporales
Is_Outlier	1 si Total > Q3 + 3×IQR, 0 si no	Indicador de pedidos atípicos
Segmento_Cliente	K-Means (3 clusters)	Segmentación por valor y frecuencia


4. Análisis Exploratorio de Datos (EDA)

4.1 Ventas y Beneficio por Categoría de Producto




La categoría Technology domina ampliamente el negocio con 831.273 € en ventas totales (68,9% del total), seguida de Office Supplies con 342.518 € (28,4%) y Furniture con únicamente 31.920 € (2,6%). En cuanto al beneficio, Technology aporta el 69,7% del beneficio total, confirmando que es el motor principal del negocio. Office Supplies, aunque es la categoría más activa en número de pedidos (805 pedidos frente a 207 de Technology), genera un margen relativo inferior (42,8% vs 52,8%). Furniture presenta el menor volumen pero un margen relativo similar al de Technology (52,8%).

4.2 Rendimiento del Equipo Comercial




El equipo comercial está formado por 14 agentes. Yvette Biti lidera el ranking tanto en ventas (155.655 €) como en beneficio (74.072 €), seguida de Natasha Song (128.374 €) y Tina Carlton (126.612 €). Connor Betts, con el mayor número de pedidos (159), ocupa la cuarta posición en ventas (121.228 €), lo que apunta a un perfil de pedidos de menor importe unitario. Se observa una concentración notable: los 5 primeros agentes generan el 62,4% de las ventas totales.

4.3 Evolución Temporal de Ventas



La serie temporal mensual muestra un patrón de crecimiento con alta variabilidad. 2015 fue el año con mayor facturación (383.167 €), con un crecimiento del 83,2% respecto a 2013. La tendencia acumulada confirma un crecimiento sostenido hasta mediados de 2016, con cierta contracción en la segunda mitad de ese año. Los meses de mayor actividad concentran pedidos de alto valor en Technology, explicando los picos pronunciados de la curva mensual.


4.4 Clientes por Tipología y Prioridad de Pedido



El segmento Corporate lidera en ventas totales (413.342 €) gracias a su mayor volumen de pedidos (377). Sin embargo, Small Business destaca por su mayor ticket medio (1.362 € vs 1.096–1.143 € del resto), lo que lo convierte en el segmento de mayor valor unitario. Los pedidos de prioridad High concentran el mayor volumen de ventas, seguidos de Medium y Critical. Los pedidos Not Specified representan un volumen notable que merece una política de clasificación más rigurosa.

5. Aplicación de Técnicas de Business Analytics


5.1 Análisis de Correlación



La matriz de correlación revela las siguientes relaciones clave entre variables numéricas:

- Total y Profit presentan una correlación muy alta ($r = 0,971$), lo que indica que el beneficio crece proporcionalmente con las ventas.
- Cost Price y Retail Price muestran correlaciones altas con Total (0,842 y 0,831 respectivamente), confirmando que el precio unitario del producto es el principal determinante del importe del pedido.
- Shipping Cost tiene una correlación moderada con Total (0,640), reflejando que los pedidos de mayor valor tienden a generar mayores costes logísticos.
- Profit_Margin_Pct presenta correlaciones bajas con el resto de variables (máximo 0,143), lo que sugiere que el margen porcentual es independiente del volumen de ventas.
- Discount % tiene correlación prácticamente nula con Total (0,047), indicando que los descuentos no están estructurados en función del importe del pedido.

5.2 Análisis de Regresión Lineal




Se desarrolló un modelo de regresión lineal múltiple para predecir el importe total del pedido (Total) a partir de cuatro variables independientes: Order Quantity, Retail Price, Discount % y Shipping Cost. El modelo se entrenó con el 80% de los datos (831 registros) y se evaluó sobre el 20% restante (208 registros).

Métrica	Valor	Interpretación
R^2 (coeficiente de determinación)	0,7616	El modelo explica el 76,2% de la varianza del Total
MAE (error absoluto medio)	830,96 €	Error promedio de predicción de 830,96 €
Coeficiente Order Quantity	53,74	Cada unidad adicional incrementa el pedido en 53,74 €
Coeficiente Retail Price	25,19	Cada euro de PVP adicional incrementa el pedido en 25,19 €
Coeficiente Discount %	869,91	Un descuento mayor se asocia a pedidos de mayor volumen
Coeficiente Shipping Cost	18,22	El coste de envío tiene un efecto moderado sobre el total

El modelo presenta un buen ajuste ($R^2 = 0,76$) considerando que se emplean solo 4 predictores. El elevado MAE refleja la gran dispersión inherente al dataset, principalmente causada por pedidos atípicos de Technology de alto valor. El precio de venta al público (Retail Price) y la cantidad pedida (Order Quantity) son los predictores con mayor relevancia interpretativa.

5.3 Segmentación de Clientes (K-Means)



Se aplicó el algoritmo K-Means con $k=3$ clusters sobre las variables Frecuencia de compra, Ventas Totales y Ticket Medio de cada cliente único. Los resultados identifican tres segmentos diferenciados:

Segmento	Frecuencia Media	Ventas Medias (€)	Ticket Medio (€)	Perfil
Premium	2,42	17.890	8.186	Pocos clientes, alto valor unitario — probable Technology
Ocasional	3,60	1.990	544	Alta frecuencia, bajo valor — productos de Office Supplies
Inactivo	1,35	968	701	Baja frecuencia y bajo volumen — clientes esporádicos

Los clientes Premium representan el mayor valor estratégico para el negocio a pesar de su menor frecuencia de compra. Los clientes Ocasionales, aunque compran con mayor regularidad, generan tickets más bajos y requieren estrategias de upselling. Los clientes Inactivos son candidatos a programas de reactivación.

5.4 Análisis de Series Temporales

El análisis temporal por año refleja un crecimiento acumulado significativo desde 2013 hasta 2015, con una ligera contracción en 2016:

Año	Pedidos	Ventas (€)	Beneficio (€)	Crec. Ventas YoY
2013	229	185.547	92.564	—
2014	242	339.841	154.853	+83,2%
2015	285	383.167	164.769	+12,8%
2016	258	273.561	136.535	-28,6%
2017	25*	23.596	13.156	Datos parciales

(*) Los datos de 2017 son parciales, cubriendo únicamente los meses de enero y febrero. La caída de 2016 respecto a 2015 merece atención: podría reflejar una reducción en la captación de nuevos clientes o en el volumen de pedidos de Technology, la categoría de mayor impacto.

6. Recomendaciones para la Toma de Decisiones

A partir del análisis realizado, se formulan las siguientes recomendaciones estratégicas, ordenadas por horizonte temporal de implementación:

Recomendación 1 — Reforzar la Estrategia Comercial en Technology

Technology concentra el 68,9% de las ventas y el 69,7% del beneficio con un margen relativo del 52,8%. La dependencia de esta categoría es a la vez una fortaleza y un riesgo. Se recomienda:

- Ampliar el catálogo de productos Technology, priorizando los de mayor margen relativo.
- Crear incentivos comerciales específicos para los agentes que desarrollen nuevas cuentas en esta categoría.
- Establecer acuerdos marco con clientes Corporate y Small Business para pedidos recurrentes de alto valor.

Justificación: Yvette Biti, la top performer, genera el 86,4% de su beneficio desde pedidos de Technology. La correlación entre Retail Price y Total ($r = 0,83$) confirma que los productos de alto precio unitario son los principales generadores de ingresos.

Recomendación 2 — Desarrollar el Segmento Small Business

Small Business presenta el mayor ticket medio (1.362 €/pedido) de los cuatro segmentos de cliente, por encima de Corporate (1.096 €), Consumer (1.143 €) y Home Office (1.095 €). Sin embargo, es el tercer segmento en volumen total de ventas.

- Diseñar un programa de fidelización B2B dirigido específicamente a Small Business.
- Asignar agentes de cuenta dedicados a los clientes Small Business clasificados como Premium en el clustering.
- Desarrollar propuestas de valor diferenciadas (financiación, descuentos por volumen, soporte prioritario).

Justificación: El clustering K-Means identifica un grupo de clientes Premium con ticket medio de 8.186 €. La mayoría corresponde a clientes Small Business con pedidos de Technology de alto valor.

Recomendación 3 — Política de Descuentos Basada en Datos

El análisis de correlación muestra que Discount % tiene una correlación prácticamente nula con Total ($r = 0,047$), lo que sugiere que la política de descuentos actual no está alineada con el valor del pedido. El coeficiente de regresión positivo (869,91) indica que los descuentos mayores se asocian a pedidos de mayor importe, no al revés.

- Revisar la política de descuentos para orientarla hacia la generación de volumen adicional (descuentos por cantidad mínima de unidades o importe).
- Eliminar descuentos en productos de alta rotación y margen elevado donde no son necesarios para cerrar la venta.

Recomendación 4 — Acciones para Revertir la Tendencia de 2016

Las ventas de 2016 cayeron un 28,6% respecto a 2015. Este declive requiere una investigación específica para identificar sus causas (pérdida de clientes clave, reducción de pedidos de Technology, factores estacionales) y diseñar un plan de recuperación para 2017.

- Analizar la evolución individual de los clientes Premium para detectar bajas o reducción de actividad.
- Reforzar las acciones comerciales en Q1 y Q3, trimestres históricamente de menor actividad.
- Implementar alertas tempranas (dashboards) que notifiquen desviaciones mensuales superiores al 15% sobre el plan.

Recomendación 5 — Optimizar la Categoría Furniture

Furniture representa apenas el 2,6% de las ventas con solo 27 pedidos en 4 años, aunque su margen relativo (52,8%) es comparable al de Technology. El bajo volumen puede indicar falta de visibilidad o de esfuerzo comercial dedicado.

- Evaluar si la escasa actividad en Furniture es una decisión estratégica deliberada o una oportunidad desaprovechada.
- Si se decide potenciar la categoría, asignar objetivos específicos de Furniture a 2-3 agentes y medir su evolución.

7. Conclusiones

El análisis completo del dataset Shipping Data (2013–2017) ha permitido extraer conclusiones relevantes para la gestión del negocio. Desde una perspectiva metodológica, el proceso seguido — exploración, limpieza, EDA, análisis de correlación, regresión lineal, segmentación K-Means y análisis temporal — ha proporcionado una visión integral del rendimiento comercial de la empresa.

Los hallazgos más significativos son: la concentración del negocio en Technology (69% de ventas y beneficio), la existencia de un segmento Premium de clientes de alto valor, el sólido margen relativo del negocio (46,6% de media), y una tendencia de crecimiento positiva aunque con una contracción preocupante en 2016.

Las recomendaciones formuladas están respaldadas por evidencia estadística y pueden implementarse con recursos comerciales existentes en el corto y medio plazo, con impacto esperado en la recuperación del volumen de ventas y la mejora de la eficiencia comercial del equipo.

Jesús Gerardo Sánchez Cárdenas — Reto 3 · Business Intelligence y Big Data